

LipidIN × Agent — code 使用手册（中文）

面向 **非靶向脂质组学** 的对话式、大模型辅助流程：注释 → 定量 → 质控 → 差异分析 → 生物学结论 → 带验证的报告。

English version: [README_EN.md](#) 。碳碳双键定位 (Paternò-Büchi) 请见姊妹目录 [code_for_PB](#) 。

本手册基于对整个流程的实际通读，以及对自带 demo 数据的真实启动编写。下文所有界面截图均来自实时运行的界面。

1. 它能做什么

给定样品的 LC-MS/MS 数据，本流程：

1. **转换**：厂商原始文件 / mzML → 标准 pkl。
2. **注释**：MS2 搜库（对 LipidIN 理论谱库）。
3. **保留时间** 推断 / 对齐校验。
4. 构建 **注释总表**。
5. **定量**：EIC 提取 + 峰积分。
6. **质控**：总峰面积校正、CV、PCA、PLS-DA。

助手在此之上追加：差异分析（火山图 / 热图 / 脂肪酸变化 / 类别气泡 / 随机森林）、通路富集（LIPID MAPS）、大模型生成的生物学结论、四维验证（注释 / RT / 生物学 / 文献），以及中英双语 Markdown 报告。

2. 运行环境

项目	要求
系统 / Python	Windows x64 + CPython 3.11 (C++ 引擎以 <code>*.cp311-win_amd64.pyd</code> 形式提供)
内存	≥ 16 GB (理论谱库较大；16 GB 用 1 个搜库线程)
Python 包	<code>flask pandas numpy scipy scikit-learn matplotlib polars fisher_py</code>
读取 Thermo <code>.raw</code>	<code>fisher_py</code> + .NET (自带)
SCIEX <code>.wiff</code> / Bruker/Agilent <code>.d</code>	需 ProteoWizard msconvert 在 PATH 中 (自动转 mzML)
谱图库	从 Zenodo 下载 → https://zenodo.org/records/21421866 (<code>pos_common.pkl</code> 、 <code>neg_common.pkl</code>)，放进 <code>library/</code> 目录
大模型 (可选)	Anthropic / OpenAI 兼容 / DeepSeek 的密钥。结构化命令离线可用；仅自由文本请求、结论、解读需要它。

3. 准备数据

按极性组织输入：

```
<数据根目录>/
├ pos/      # 正模式  A1.raw, A2.raw, ... , B1.raw, ... , (QC1, QC2, ... )
└ neg/      # 负模式  A1.raw, ...
```

- 样本主名编码分组 (**A*** vs **B***) ; 名字含 **QC** 的按混合质控处理。
- 支持 **.mzML**、Thermo **.raw**、SCIEX **.wiff**、Bruker/Agilent **.d**。
- 自带 demo 位于 **D:\bio_inf\LipidIN_github\data** (**pos/** 与 **neg/** , 各 13 个文件)。

4. 两种运行方式

方式 A — 一键批处理 (**run.py**)

打开 **run.py** , 修改顶部三行:

```
POLARITY      = "pos"                                # "pos" 或 "neg"
DATA_ROOT     = r"D:\bio_inf\LipidIN_github\data"
LIBRARY_DIR   = r"D:\bio_inf\LipidIN_github\library"
```

然后:


```
D:\anaconda3\python.exe run.py
```

它对该极性跑第 1-6 步, 写出 **master_table.csv**、**master_table_quant.csv** 和 **QC_<极性>/** 目录。16 GB 上保持 **EQ3_WORKERS = 1**。每个极性各跑一次。

方式 B — 对话式助手 (推荐)

```
D:\anaconda3\python.exe agent_server.py
# 打开 http://127.0.0.1:7860
```

界面分三栏: **左** = 实时参数、组别与对照、生物学问题; **中** = 对话; **右** = 引用格式。



5. 一个完整的标准对话

下面是针对 demo 的真实会话。

5.1 求助 — 帮助

助手列出命令：配置大模型、分步运行（[注释](#) / [定量](#) / [质控](#) / [差异分析](#) / [生成结论](#) / [确认](#)）、[运行全流程](#)，以及如何改参数（病例/对照、等级筛选、CV 阈值、ppm/Da、生物学背景）。



脂质谱学分析 · 对话式 · 大语言模型

中 / EN

运行状态 Live status

运行参数

数据目录

D:\bio_inf\LipidIN_github\上传版本\LipidIN-main\LipidIN x Agent\common_demo

数据库目录

D:\bio_inf\LipidIN_github\上传版本\LipidIN-main\LipidIN x Agent\Library

极性/文件

pos=0 neg=0

置信等级

all

仅MS1

on

CV筛选

off

类别RT规则

none

质量精度

MS1 10 / MS2 25 ppm

大模型

none

组别与对照

对照组合

尚未设置对照

设置对照

支持多组对照：可输入“对照 B vs A, C vs A”或“两两对照”一次跑多组差异，生物学问题

尚未设置生物学问题。可在对话框输入：背景：肝癌 vs 肾癌

设置生物学问题

你好，我是 LipidIN 助手。左栏实时显示运行参数、组别与对照（支持多组对照）、生物学问题；右栏是多步运行流程。

建议先“配置大模型”，然后“运行全流程”，或分步：注释→定量→质控→差异分析→生成结论→确认。

支持 mzML, 以及 Thermo .raw SCIEX .wiff 原始文件。

Hi, I am the LipidIN assistant. Left column: live parameters, groups & comparisons (multi-group), biological question. Right column: citation formats. Also accepts Thermo .raw / SCIEX .wiff.

我可以运行整个脂质谱分析流程。建议第一步先『配置大模型』，配置后即可用自然语言下达要求。

- 配置大模型：回复“配置大模型”，我会带你填写 提供方/密钥/模型
- 分步运行：注释（仅定性）/ 定量（仅定量）/ 质控（仅质控）/ 差异分析（仅差异分析）/ 生成结论 / 确认（验证并出报告）
- 运行全流程：定性→定量→质控→差异分析→生物学问题一次跑完
- 改参数：病例 B 对照 A、等级 1,2、排除 ms1-only、cv 25、ms2 ppm 20、背景：肝癌 vs 肾癌
- 个性化（配置大模型后）：如“FA类RT严格，其它类别宽松”
- 每次运行前我都会让你确认目录/极性/质谱/分组等参数；随时可改参数并重跑某一步

配置大模型

运行全流程

注释

定量

质控

差异分析

两两对照

生成结论

确认

帮助

输入指令，如：运行全流程 / 病例 B 对照 A / 两两对照 / FA类RT严格

引用格式 How to cite

LipidIN

Nature Communications 2025, 16:4566 · Xu H. et al.

查看文章

NATURE STYLE

Xu H., Jiang T., Lin Y. et al. LipidIN: a comprehensive repository for flash platform-independent annotation and reverse lipidomics. Nat. Commun. 16, 4566 (2025).

SCIENCE STYLE

Xu H., Jiang T., Lin Y. et al., LipidIN: a comprehensive repository for flash platform-independent annotation and reverse lipidomics. Nat. Commun. 16, 4566 (2025).

CELL STYLE


Xu H. (2025) LipidIN: a comprehensive repository for flash platform-independent annotation and reverse lipidomics. Nat. Commun. 16, 4566

ACS

Xu H.; Jiang, T.; Lin, Y.; Zhang, L.; Yang, H.; Huang, X.; Mao, R.; Yang, Z.; Zeng, C.; Zhao, S.; Di, L.; Zhang, W.; Zeng, J.; Cai, Z.; Lin, S.-H. LipidIN: A Comprehensive Repository for Flash Platform-Independent Annotation and Reverse Lipidomics. Nat. Comm. 2025, 16, 4566.

BIBTEX

@article{Xu2025LipidIN, title={LipidIN: a comprehensive repository for flash platform-independent annotation and reverse lipidomics}, author={Xu, Hao and Jiang, Tianhang and Lin, Yuxiang and Zhang, Lei and Yang, Huan and Huang, Xiaoyun and Mao, Ridong and Yang, Zhu and Zeng, Changchun and Zhao, Shuang and Di, Lijun and Zhang, Wenbin and Zeng, Jun and Cai, Congwei and Lin, Shu-Haili},



如图，它检测到 `pos=13, neg=13`，样本 `A1..B5, QC1..QC3`，分组 `A×5, B×5, QC×3`，对照 `B vs A`，并校验了 `pos_common.pkl ✓ neg_common.pkl ✓`。

5.4 对话中随时改参数

任意参数都可随时修改，且只重跑受影响的下步步骤：

- 对照：病例 `B 对照 A`，或 `B vs A, C vs A`，或 `两两对照`。
- 置信等级筛选：等级 `1,2`（Level 1 = MS2 且诊断碎片齐全；2 = MS2 但有碎片缺失；3 = MS1 推断）。
- 排除 `ms1-only`、`cv 25`、`ms2 ppm 20`。
- 按类别的 RT 严格度（需大模型）：`[FA 类 RT 严格, 其它类别宽松]`。
- 生物学问题：背景：`肝癌 vs 癌旁`。

5.5 结论与报告

`生成结论` → 助手起草生物学结论；`确认` 运行四维验证并写出 `LipidIN_report.md`（注释结果、质控、差异分析 + 通路、带验证表的结论、附录）。

6. 产物说明（输出）

文件 / 目录	含义
<极性>/pkl/master_table.csv	注释总表（物种、证据类型、RT 判定）
<极性>/pkl/master_table_quant.csv	每样本定量（EIC 峰面积）
QC_<极性>/	总峰面积校正表 + CV / PCA / PLS-DA 图
differential_*.csv + PNG	火山图 / 热图 / 脂肪酸 / 类别气泡 / 随机森林
pathway_enrichment_*.png/.csv	LIPID MAPS 通路富集
<数据根目录>/agent_report/LipidIN_report.md	最终中英双语报告

7. 常见报错与排查（预设问题）

- ① `ImportError: eq3_search / eq3_similarity`（C++ 引擎载入失败）。引擎是为 **CPython 3.11**、**Windows x64** 预编译的（`*.cp311-win_amd64.pyd`）。版本或平台不匹配就导入失败。解决：用 **Windows x64 上的 Python 3.11** 运行。`eq3_similarity` 可由源码重编（`build_cpp.py / compile_cpp_similarity.py`，需 MSVC + pybind11）；但 `eq3_search` **本目录没有源码**（`compile_cpp_fixed.py` 甚至指向一个并不存在的硬编码 `EQ3.cpp` 路径），因此必须保留自带 `.pyd` 并匹配 Python 3.11。
- ② **找不到库文件**。`pos_common.pkl / neg_common.pkl` 因体积过大 **不在仓库里**。请从 <https://zenodo.org/records/21421866> 下载到 `library/`，并把 `LIBRARY_DIR` / 助手指向它。
- ③ `MemoryError` / 频繁换页。库需要 ≥ 16 GB。16 GB 机器上保持 `EQ3_WORKERS = 1`，一次只跑一个极性。
- ④ `.wiff / .d` 未处理 / 「找不到 `msconvert`」。非 Thermo 的厂商格式通过 ProteoWizard `msconvert` 转换——请安装并确保在 PATH 中。Thermo `.raw` 直接读取（无需 `msconvert`），但需要 `fisher_py` 的 .NET 后端。
- ⑤ **对话框中含空格的路径被截断**。助手会在第一个空格处截断输入的路径。请用 **不含空格** 的数据/库路径，或改用 `run.py` 设置。
- ⑥ **分组错误或为空**。分组来自样本主名（`A*` vs `B*`，`QC*` = 混合质控）。识别不对时显式设置：`病例 B 对照 A`。为空说明 `pos/ neg/` 下没找到文件——请检查目录布局。
- ⑦ **端口被占用**。`7860` 被别的进程占用。修改 `agent_server.py` 底部的端口，或释放该端口。
- ⑧ **控制台乱码 / `UnicodeEncodeError`**。入口已强制 UTF-8；若在 GBK 控制台直接调用某模块可能乱码——请走 `run.py / agent_server.py`，或设置 `PYTHONIOENCODING=utf-8`。
- ⑨ **大模型功能没反应**。未配置提供方时，结构化命令仍可运行；自由文本请求、按类别 RT 规则、生物学结论与解读需要大模型密钥。

8. 引用

